



CBU Coding Challenge

Project: Scoring

Group: Mix Data



Duch kelgan muammolar

Ma'lumotlarning turliligi

Ma'lumotlar turli fayllarda va bir-biriga qanday bog'lik ekanligini topish muammosi.

EDA muammolari

1. Defolt xolatlari juda kamligi
2. Ba'zi ma'lumotlar yo'qligi
3. Ustunlar xar hil nom bilan takrorlangaligi va multikollinearlik

Feature selection

60 dan ortiq ustunlar va ularning natijaga qanday darajada ta'sir qilishini aniqlash.

Group: Mix Data

Muammolarni hal qilish yo'llari




Ma'lumotlarni birlashtirish

Turli faylarni o'zro birlashtiruvchi ustunni aniqlash va shu yordamida ma'lumotlarni bitta yaxlit ma'lumotlar to'plamiga keltirish.



Ma'lumotlar to'liqligi va to'g'rilibini taminlash

Ma'lumotlarni ta'sir qilish darajasi va ma'nosiga qarab yetishmagan ma'lumotlarni to'ldirish, bir xil ma'lumotlar turiga olib kelish, ta'sir darajasi quyi bo'lgan ma'lumotlarni tozalash.



Korralatsyon ta'sirni aniqlash

Hamma ustunlar bo'yicha korralatsiya darajasini aniqlash va kerakli ustunlarni tanlab olish, bazi ustunlar yordamida korralatsiya darjasini yuqori yangi ustunlarni yaratish

Group: Mix Data



Modellarni o'qitish va muqobil modelni tanlash

Biz eng samarali kredit ballari modelini aniqlash maqsadida uchta asosiy algoritmnini o'qitdik va taqqosladik:

- **Logistic Regression**
- **Random Forest**
- **CatBoost**

Har bir model ma'lumotlar to'plamimizda sinovdan o'tkazildi va ularning ishlash ko'rsatkichlari, aniqligi va mustahkamligi tahlil qilindi. Bu taqqoslash natijasida eng yuqori baholash sifatini ta'minlaydigan optimal model tanlandi.

Group: Mix Data

Tanlangan model arxitekturasi: CatBoost Classifier

- Kategorik xususiyatlarni avtomatik qayta ishlash
- Anomaliyalarga chidamlik.
- Nomutanosib maqsadli o'zgaruvchiga moslasha olish
- Yuqori samaradorlik
- AUC: ~0.81 (cv)

Yaratilgan model

Afzalliklari


- **Yuqori aniqlik:** Murakkab munosabatlarni aniqlay oladi.
- **Optimallashtirilgan:** Katta ma'lumotlar bilan samarali ishlaydi.
- **Moslashuvchan:** Turli vazifalarga moslashish imkoniyati. Hamda turli xildagi datalar uchun qulay
- **O'zaro bog'liqlikni aniqlash:** Xususiyatlar orasidagi nozik aloqalarni topa oladi.

Kamchiliklari

- **Murakkablik:** Tushunish va sozlash biroz qiyinroq.
- **Manba talabchan:** Yuqori hisoblash resurslarini talab qilishi mumkin.
- **Izohlilik:** Ba'zan natijalarni sharhlash qiyin bo'lishi mumkin.
- **Giperparametr topish:** Optuna hamda qo'lida giperparameterlar sozlangan.



Group: Mix Data



SHAP

Top influencing parameters

- **Credit score.** Kichikroq bo'lsa defolt riski katta;
- **Income.** Kattaroq bo'lsa defolt riski kichrayadi;
- **Age.** Kattalar to'lay olmaydigan kreditni kamroq olishadi;
- **Credit pressure (hisoblangan qiymat).** Kamroq bo'lsa kredit to'lash osonroq;

E'tiboringiz uchun
Rahmat